# ÁP DỤNG CÁC MÔ HÌNH HỌC SÂU VÀ XỬ LÝ NGÔN NGỮ TỰ NHIÊN VÀO HỆ THỐNG PHÂN TÍCH HỒ SƠ ỨNG VIÊN

LÂM QUANG PHÚ [1] (*), TRỊNH NGUYỄN HOÀNG VŨ [1], LÊ PHÚC LỮ [1],

**Tóm tắt:** Hiện nay, sự phổ biến của các nền tảng tuyển dụng trực tuyến đã tạo ra số lượng lớn, lên đến hàng nghìn lý lịch ứng viên gửi đến các doanh nghiệp mỗi tháng. Điều này khiến cho việc sàng lọc và xác định ứng viên phù hợp cho từng vị trí cụ thể trở nên cực kỳ phức tạp và tốn kém nếu chỉ thực hiện thủ công. Việc này không những là thách thức đối với nhà tuyển dụng mà cũng là một phần lý do khiến cho nhiều ứng viên chưa tìm được công việc phù hợp. Để giải quyết vấn đề này, nghiên cứu của chúng tôi áp dụng các kỹ thuật xử lý ngôn ngữ tự nhiên (NLP) kết hợp với các mô hình học sâu (Deep Learning) nhằm phát triển một hệ thống phân tích lý lịch tự động. Hệ thống này có khả năng tự động trích xuất thông tin quan trọng từ hồ sơ ứng viên, hỗ trợ nhà tuyển dụng chọn ra ứng viên phù hợp nhất, từ đó tối ưu hóa quy trình tuyển dụng. Chúng tôi tin rằng phương pháp tiếp cận của mình có tiềm năng đáng kể để sử dụng trong môi trường doanh nghiệp, nơi việc phân tích sơ yếu lý lịch hiệu quả và chính xác là rất quan trọng để tuyển dụng thành công.

**Từ khóa:** Xử lý ngôn ngữ tự nhiên, Học sâu, Hồ sơ tuyển dụng, Phân tích hệ thống, PDF format, BERT, LayoutLMv3.

**Lĩnh vực:** Điện – Điện tử – Công nghệ thông tin.

# APPLYING DEEP LEARNING AND NATURAL LANGUAGE PROCESSING TO THE CANDIDATE PROFILE ANALYSIS SYSTEM

**Abstract:** Currently, the widespread use of online recruitment platforms has led to a massive influx, reaching thousands of resumes sent to businesses each month. This makes the process of screening and identifying suitable candidates for specific positions extremely complex and costly if done manually. This not only poses a challenge for employers but also partly explains why many candidates have not found suitable jobs. To address this issue, our research applies natural language processing (NLP) techniques combined with deep learning models to develop an automatic resume analysis system. This system can automatically extract key information from candidates' resumes, helping employers select the most suitable candidates, thereby optimizing the recruitment process. We believe that our approach has significant potential for use in corporate environments, where effective and accurate resume analysis is crucial for successful recruitment.

**Keyword:** Natural language processing, Deep learning, CV, System parser, PDF format, BERT, LayoutLM.

## 1. GIỚI THIỆU

Sự phát triển mạnh mẽ của công nghệ thông tin đã làm thay đổi cách thức quản lý và xử lý dữ liệu trong nhiều lĩnh vực, đặc biệt là tuyển dụng nhân sự. Các nền tảng tuyển dụng trực tuyến hiện nay đã tạo ra một lượng lớn hồ sơ ứng viên gửi đến các doanh nghiệp mỗi tháng, khiến việc sàng lọc và xác định ứng viên phù hợp trở nên cực kỳ phức tạp và tốn kém nếu chỉ thực hiện thủ công. Điều này không chỉ là thách thức đối với nhà tuyển dụng mà còn khiến nhiều ứng viên chưa tìm được công việc phù hợp.

Để giải quyết vấn đề này, nghiên cứu của chúng tôi áp dụng các kỹ thuật xử lý ngôn ngữ tự nhiên (NLP) kết hợp với các mô hình học sâu (Deep Learning) nhằm phát triển một hệ thống phân tích lý lịch tự động. Hệ thống này có khả năng tự động trích xuất thông tin quan trọng từ hồ sơ ứng viên, hỗ trợ nhà tuyển dụng chọn ra ứng viên phù hợp nhất, từ đó tối ưu hóa quy trình tuyển dụng. Cụ thể, chúng tôi sử dụng các mô hình ngôn ngữ tiên tiến như BERT và LayoutLM để phân loại từ trong hồ sơ ứng viên thành các nhãn xác định trước. Sau đó, áp dụng thuật toán heuristic để chuyển đổi danh sách token và nhãn thành định dạng có cấu trúc như JSON, giúp việc xử lý và sử dụng thông tin trở nên dễ dàng hơn. Hệ thống này không chỉ cải thiện độ chính xác mà còn tăng hiệu quả và tốc độ xử lý, đáp ứng nhu cầu tuyển dụng ngày càng cao của các doanh nghiệp.

## 2. CÁC NGHIÊN CỨU LIÊN QUAN

Các nghiên cứu gần đây đã đạt được nhiều tiến bộ trong việc phân tích tài liệu và trích xuất thông tin từ các bộ dữ liệu phong phú, bao gồm bảng, biên nhận, biểu mẫu và nhiều định dạng khác nhau như PDF, DOCX và hình ảnh. BERT, một mạng thần kinh dựa trên bộ mã hóa biến áp, đã chứng minh hiệu quả vượt trội trong các nhiệm vụ hiểu ngôn ngữ [1]. Xu và cộng sự đã cải tiến BERT thành LayoutLM bằng cách thêm nhúng tọa độ không gian 2D và các tính năng trực quan, giúp xử lý biểu mẫu và phân loại biên nhận [2]. LayoutLMv2 tiếp tục nâng cấp bằng cách coi các tính năng trực quan như các token riêng biệt và bổ sung các nhiệm vụ huấn luyện trước [3].

Das và cộng sự đã phát triển một mô hình trích xuất thực thể cho phân tích sơ yếu lý lịch, đạt độ chính xác 87,78% trên 100 CV [5], trong khi Berty và cộng sự sử dụng mạng CNN và RNN để phân tích sơ yếu lý lịch bằng tiếng Indonesia, đạt độ chính xác 89,25% [7]. Mặc dù các mô hình dựa trên quy tắc có sẵn, các mô hình học sâu như BERT và LayoutLM vẫn được ưa chuộng hơn nhờ độ chính xác cao trong các nhiệm vụ phức tạp. Tuy nhiên, triển khai các mô hình này trong thực tế gặp nhiều thách thức về khả năng mở rộng.

Tại Việt Nam, nghiên cứu và ứng dụng các kỹ thuật trích xuất thông tin cũng đã có những bước tiến quan trọng. Hệ thống V-CitationGate do Đại học Quốc gia Hà Nội khởi động, tích hợp và đánh giá các bài báo khoa học trong nước và quốc tế, giúp theo dõi và so sánh chất lượng các tạp chí khoa học Việt Nam [9]. Các kỹ thuật xử lý ngôn ngữ tự nhiên (NLP) và trích xuất thông tin đã dần được áp dụng để xử lý các văn bản tiếng Việt, bao gồm nghiên cứu về OCR (nhận dạng ký tự quang học) và xử lý văn bản phi cấu trúc.

## 3. CƠ SỞ LÝ THUYẾT

### 3.1. Xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP):

Xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP) là một lĩnh vực trong khoa học máy tính, tập trung vào sự tương tác giữa con người và máy tính thông qua ngôn ngữ tự nhiên. Trong lĩnh vực nhân sự, NLP được áp dụng để tự động hóa và cải thiện quá trình phân tích hồ sơ ứng viên. Các hệ thống NLP sử dụng các kỹ thuật như trích xuất thực thể có tên (Named Entity Recognition - NER) để xác định và phân loại các thông tin quan trọng từ hồ sơ, như tên, địa chỉ, trình độ học vấn và kinh nghiệm làm việc [1], [4]. Phân tích cảm xúc (Sentiment Analysis) cũng được sử dụng để đánh giá ngữ điệu và cảm xúc trong hồ sơ xin việc, giúp nhà tuyển dụng hiểu rõ hơn về thái độ và động lực của ứng viên [6]. Sau khi trích xuất thông tin, các hệ thống này có thể tổ chức lại thông tin thành các định dạng có cấu trúc để dễ dàng tìm kiếm và phân tích.

### 3.2. Transformers

Transformers là một kiến trúc mạng nơ-ron học sâu, đã tạo ra bước đột phá lớn trong xử lý ngôn ngữ tự nhiên (NLP). Được giới thiệu bởi Vaswani và cộng sự vào năm 2017, Transformers sử dụng cơ chế attention đặc biệt để xử lý và tạo ra ngôn ngữ tự nhiên một cách hiệu quả hơn so với các mô hình trước đó [10]. Thay vì dựa vào các mạng nơ-ron hồi quy (Recurrent Neural Networks - RNN) hoặc các mô hình chuỗi, Transformers cho phép xử lý song song dữ liệu và mở rộng khả năng học hỏi từ các chuỗi dài hơn. Cơ chế này cho phép mô hình xác định tầm quan trọng của từng từ trong một chuỗi văn bản đối với các từ khác, giúp cải thiện hiệu suất trong việc hiểu ngữ cảnh và các mối quan hệ phức tạp giữa các từ [10]. Một số biến thể nổi bật của Transformers bao gồm BERT (Bidirectional Encoder Representations from Transformers), GPT-2 (Generative Pre-trained Transformer 2). Các mô hình này đã đạt được kết quả tiên tiến trong nhiều nhiệm vụ NLP như dịch ngôn ngữ, phân tích cảm xúc, và trả lời câu hỏi [1].

#### 3.2.1. Positional Encoding

Transformers, mặc dù vượt trội trong nhiều nhiệm vụ xử lý ngôn ngữ tự nhiên, không có khả năng tự nhiên để nhận biết thứ tự tuần tự của các từ trong một chuỗi. Để giải quyết vấn đề này, kiến trúc Transformer sử dụng kỹ thuật Positional Encoding để cung cấp thông tin về vị trí của các từ trong chuỗi đầu vào. Kỹ thuật cho phép mô hình duy trì thông tin về thứ tự các từ mà không cần phải dựa vào cấu trúc tuần tự như trong các mạng nơ-ron hồi quy truyền thống [10].

Positional Encoding hoạt động bằng cách thêm các vector vào các embeddings của từ để biểu diễn vị trí của từ trong chuỗi. Điều này đạt được bằng cách thêm một tập hợp các hàm hình sin, cos có thể học được vào phần nhúng của mỗi token đầu vào. Cụ thể, các vị trí lẻ và vị trí chẵn trong chuỗi được mã hóa bằng cách sử dụng các hàm sin và cos với các tần số khác nhau để đảm bảo rằng mỗi vị trí trong chuỗi có một mã hóa duy nhất được thể hiện qua (Hình 1). Sử dụng Positional Encoding, các Transformer có thể duy trì thông tin về thứ tự của các từ trong chuỗi văn bản, từ đó cải thiện khả năng hiểu ngữ cảnh và mối quan hệ giữa các từ.

$$PE_{(pos,2i)} = \sin\left(pos/10000^{2i/d_{\text{model}}}\right)$$
$$PE_{(pos,2i+1)} = \cos\left(pos/10000^{2i/d_{\text{model}}}\right)$$

Hình 1. Công thức xác định Position Encoding [10]

#### 3.2.2. Self-Attention

Cơ chế self-attention là yếu tố chính giúp Transformers vượt trội trong các nhiệm vụ xử lý ngôn ngữ tự nhiên. Cơ chế này cho phép mô hình xác định tầm quan trọng của từng từ trong một chuỗi văn bản đối với các từ khác, giúp cải thiện hiệu suất trong việc hiểu ngữ cảnh và các mối quan hệ phức tạp giữa các từ. Scaled Dot-Product Attention, một thành phần quan trọng của cơ chế này, tính toán trọng số attention bằng cách thực hiện các phép toán ma trận và áp dụng hàm softmax để lấy trọng số attention. Multi-Head Attention mở rộng khái niệm này bằng cách sử dụng nhiều đầu attention song song, cho phép mô hình học các loại thông tin khác nhau từ các phần khác nhau của chuỗi [10], được thể hiện qua (Hình 2). Các cơ chế attention này cho phép Transformer duy trì thông tin về mối quan hệ giữa các từ, cải thiện hiệu suất trong các nhiệm vụ như trích xuất thông tin văn bản, dịch ngôn ngữ, phân tích cảm xúc và nhận dạng thực thể có tên (NER) [10].

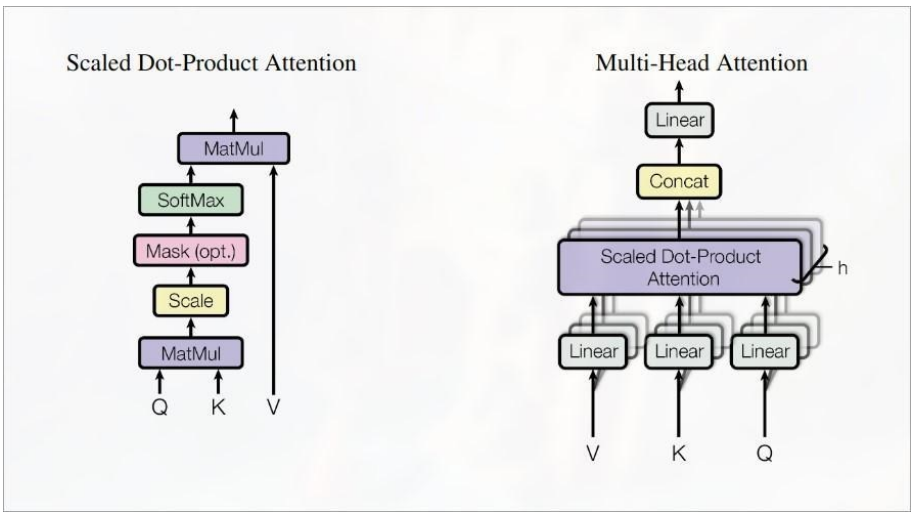


Hình 2. Scaled Dot-Product Attention [10]

### 3.3. BERT (Bidirectional Encoder Representations from Transformers)

BERT là một mô hình học sâu được giới thiệu bởi Devlin et al nhằm cải thiện các tác vụ hiểu ngôn ngữ tự nhiên. BERT sử dụng kiến trúc Transformer, cụ thể là phần encoder của Transformer, để học các biểu diễn ngữ nghĩa của từ và câu theo cách hai chiều, tức là từ trái sang phải và phải sang trái đồng thời. Mô hình được tiền huấn luyện trên một lượng lớn dữ liệu văn bản không gán nhãn thông qua hai nhiệm vụ chính: Masked Language Model và Next Sentence Prediction. Nhiệm vụ MLM yêu cầu dự đoán các từ bị che dấu dựa trên ngữ cảnh hai chiều, trong khi NSP xác định xem câu thứ hai có phải là câu tiếp theo của câu thứ nhất trong một cặp câu hay không. Nhờ vào khả năng học ngữ cảnh hai chiều và quá trình tiền huấn luyện hiệu quả, BERT đã đạt được hiệu suất vượt trội trên nhiều tác vụ NLP như trích xuất thông tin văn bản, phân loại văn bản, trả lời câu hỏi và phân tích cảm xúc, đánh dấu một bước tiến quan trọng trong lĩnh vực xử lý ngôn ngữ tự nhiên [1].

### 3.4. LayoutLM (Layout-Aware Language Model)

LayoutLM là một mô hình học sâu được phát triển bởi Xu et al để xử lý và hiểu các tài liệu có bố cục phức tạp như biểu mẫu, hóa đơn và tài liệu PDF. Mô hình này kết hợp thông tin về văn bản, hình ảnh và vị trí không gian của các từ trong tài liệu để tạo ra các biểu diễn ngữ nghĩa mạnh mẽ hơn. LayoutLM xây dựng trên nền tảng của BERT, nhưng bổ sung thêm các embedding để mã hóa vị trí không gian (x, y) và kích thước (width, height) của mỗi từ.

Dựa vào (Hình 3), LayoutLM được tiền huấn luyện trên các dữ liệu văn bản kết hợp với các thông tin về bố cục và hình ảnh. Các embedding văn bản và các embedding vị trí được kết hợp lại để tạo thành các biểu diễn đầy đủ của các từ trong tài liệu. Hình ảnh và thông tin bố cục được xử lý bởi một hệ thống OCR/PDF Parser và Faster R-CNN để trích xuất các đặc trưng ROI (Region of Interest). Các đặc trưng này sau đó được sử dụng để thực hiện các nhiệm vụ downstream tasks như trích xuất thông tin, phân loại tài liệu và nhận dạng thực thể. Kết quả từ các nhiệm vụ này được đưa vào các lớp fully connected để tạo ra các đầu ra cuối cùng.

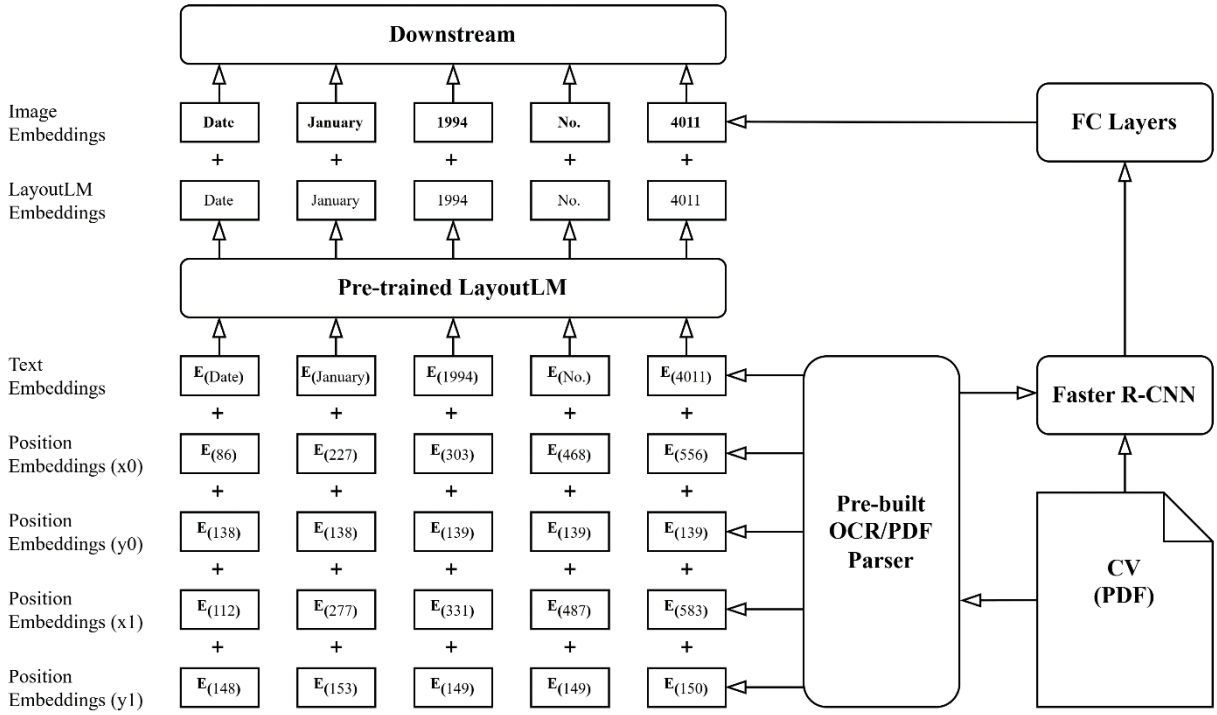


Hình 3. Kiến trúc LayoutLM

Nhờ vào khả năng kết hợp thông tin từ văn bản, hình ảnh và bố cục không gian, LayoutLM đã chứng minh hiệu suất vượt trội trong nhiều nhiệm vụ liên quan đến tài liệu có cấu trúc phức tạp, đặc biệt hữu ích trong trích xuất thông tin văn bản.

### 3.4.1. 2D Positional Encoding

LayoutLM sử dụng một cơ chế positional encoding 2D để kết hợp thông tin vị trí không gian của các từ vào mô hình. Đầu tiên, mỗi từ trong tài liệu được xác định vị trí bằng một hộp giới hạn (bounding box) với các tọa độ (x1, y1, x2, y2), đại diện cho góc trên trái và góc dưới phải của hộp giới hạn từ đó. Các tọa độ này sau đó được mã hóa thành vector tọa độ và được kết hợp với token embeddings và segment embeddings. Cụ thể, các tọa độ (x1, y1, x2, y2) được chuyển thành vector tọa độ 2D thông qua một embedding layer riêng biệt. Sau đó, vector này được cộng vào các vector nhúng từ và đoạn, tạo thành một mã hóa tổng hợp bao gồm thông tin ngữ nghĩa và vị trí không gian của từ. Cơ chế này giúp LayoutLM tận dụng cấu trúc không gian của tài liệu, từ đó cải thiện hiệu suất trong các nhiệm vụ như trích xuất thông tin và phân loại tài liệu.

## 4. PHƯƠNG PHÁP THỰC HIỆN

### 4.1. Tổng quan dữ liệu

Trong bài toán này, mục tiêu của chúng tôi là phân tích hồ sơ ứng viên để rút ra các đặc điểm và xu hướng quan trọng trong quá trình tuyển dụng. Dữ liệu được chúng tôi tiến hành thu thập từ các nhóm tuyển dụng trên Facebook và các trang web tìm kiếm việc làm khác nhau bao gồm 200 bản CV thuộc chuyên ngành công nghệ thông tin ở định dạng PDF và được viết bằng tiếng Anh. Các CV này chứa đựng thông tin chi tiết về kỹ năng, kinh nghiệm, học vấn, và các thông tin cá nhân khác của ứng viên. Sau đó chúng tôi tiến hành xử lý dữ liệu và tiến hành thống kê phân tích cũng như phân chia tập dữ liệu train test để huấn luyện mô hình.

### 4.1.1. Tiền xử lý dữ liệu

Các CV ở định dạng tệp PDF được xử lý bằng thư viện PDFMiner.six để trích xuất từng từ và hộp giới hạn của chúng dựa trên nội dung trong CV. Sau đó, chúng tôi sử dụng công cụ LabelStudio để thực hiện các tác vụ gán nhãn dữ liệu dựa trên các từ và hộp giới hạn, tạo ra tập dữ liệu chất lượng cao cho việc kiểm tra và huấn luyện mô hình.

Cuối cùng, đối với từng trang của mỗi CV, chúng tôi thu được một mảng chứa tất cả các hộp giới hạn văn bản và nhãn của mỗi từ trong văn bản, cùng với hình ảnh văn bản để đưa vào mô hình huấn luyện. Các hộp giới hạn văn bản được biểu diễn bằng tọa độ [x trái, y trên, x phải, y dưới], (Hình 4). Mỗi CV sẽ được mã hóa thành JSON tương ứng với một điểm dữ liệu, có thể bao gồm nhiều mục, mỗi mục đại diện cho một trang với các tính năng hình ảnh và các hộp giới hạn văn bản tương ứng. Quá trình tiền xử lý này đảm bảo rằng dữ liệu sẽ được chuẩn bị kỹ lưỡng, sẵn sàng cho các bước phân tích thống kê và huấn luyện mô hình tiếp theo.

```
1. [
2.     {
3.         "image": Image,
4.         "text_boxes": [
5.             {
6.                 "text": "token 1",
7.                 "box": [196, 203, 299, 301],
8.                 "label": "LABEL1"
9.             },
10.            {
11.                "text": "token 2",
13.                "box": [706, 196,907,203],
14.                "label": "LABEL2"
15.            },
16.        ],
17.    }
18. ]
19.
```

Hình 4. Format dữ liệu huấn luyện

### 4.1.2. Thống kê mô tả dữ liệu

Trong quá trình gán nhãn, chúng tôi đã chọn ra 20 nhãn quan trọng nhất trong CV, được trình bày và giải thích chi tiết ở (Bảng 1).

| | Nhãn | Giải thích |
|---|---|---|
| 1 | FULL_NAME | Tên đầy đủ của ứng viên |
| 2 | RESIDENTIAL_ADDRESS | Địa chỉ nơi cư trú của ứng viên |
| 3 | EMAIL_ADDRESS | Địa chỉ email liên hệ của ứng viên |
| 4 | PHONE_NUMBER | Số điện thoại liên hệ của ứng viên |
| 5 | DATE_OF_BIRTH | Ngày tháng năm sinh của ứng viên |
| 6 | GENDER_IDENTITY | Giới tính của ứng viên |
| 7 | PERSONAL_WEBSITE | Địa chỉ trang web cá nhân của ứng viên |
| 8 | CAREER_OBJECTIVE_TITLE | Tiêu đề mục tiêu nghề nghiệp của ứng viên |
| 9 | CAREER_OBJECTIVE_CONTENT | Nội dung chi tiết về mục tiêu nghề nghiệp của ứng |
| 10 | DEGREE_TITLE | Tiêu đề bằng cấp mà ứng viên đã đạt được |

| | | |
|---|---|---|
| 11 | EDUCATION_PERIOD_START | Thời gian bắt đầu quá trình học tập của ứng viên |
| 12 | EDUCATION_PERIOD_END | Thời gian kết thúc quá trình học tập của ứng viên |
| 13 | MAJOR_SUBJECT | Chuyên ngành học của ứng viên |
| 14 | JOB_TITLE | Tiêu đề công việc mà ứng viên đã làm |
| 15 | JOB_POSITION | Vị trí công việc mà ứng viên đã đảm nhiệm |
| 16 | EMPLOYMENT_PERIOD_START | Thời gian bắt đầu công việc của ứng viên |
| 17 | EMPLOYMENT_PERIOD_END | Thời gian kết thúc công việc của ứng viên |
| 18 | SKILL_SET | Các kỹ năng mà ứng viên sở hữu |
| 19 | ACTIVITY_TITLE | Tiêu đề hoạt động mà ứng viên đã tham gia |
| 20 | ACTIVITY_POSITION | Vị trí trong hoạt động mà ứng viên đã đảm nhiệm |
| 21 | CAREER_OBJECTIVE_CONTENT | Nội dung chi tiết về mục tiêu nghề nghiệp của ứng |
| 22 | ACADEMIC_ACHIEVEMENTS | Nội dung về thành tích học tập của ứng viên |
| 23 | PROFESSIONAL_EXPERIENCE | Nội dung về kinh nghiệm làm việc của ứng viên |
| 24 | HONORS_AND_AWARDS | Nội dung về các giải thưởng và danh hiệu mà ứng viên đã nhận được |
| 25 | HOBBIES_AND_INTERESTS | Nội dung về sở thích và mối quan tâm của ứng viên |
| 26 | REFERENCES | Nội dung về người tham chiếu của ứng viên |

Bảng 1. Danh sách các nhãn trong tập dữ liệu

Với tổng số 200 CV thuộc chuyên ngành công nghệ thông tin được thu thập, chúng tôi đã tiến hành xử lý dữ liệu và chia thành hai tập: huấn luyện và kiểm thử, như thể hiện trong (Bảng 2).

| | **Train** | **Test** |
|---|---|---|
| **CV** | 160 | 40 |
| **Trang** | 235 | 58 |

Bảng 2. Kích thước tập train và test

### 4.2. Mô hình phân tích hồ sơ ứng viên

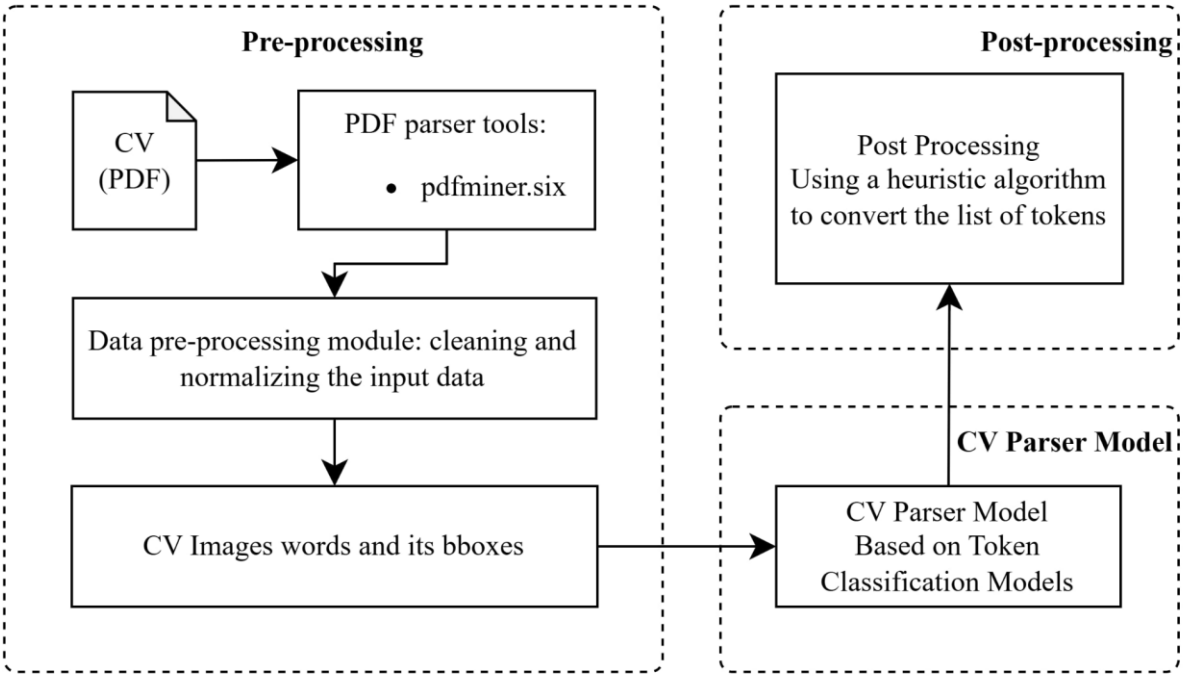


Hình 5. Kiến trúc mô hình phân tích hồ sơ ứng viên

Ở phần này chúng tôi sẽ sử dụng các mô hình ngôn ngữ được huấn luyện sẵn như BERT và LayoutLM để phân loại từ trong CV thành các nhãn đã được xác định trước. Bước này liên quan đến việc chuyển đổi CV thành các từ sau đó thực hiện gán nhãn cho từng từ bằng mô hình. Đầu ra của bước này là danh sách các token và nhãn tương ứng của chúng. Sau đó chúng tôi áp dụng thuật toán heuristic để chuyển đổi danh sách token và nhãn thành định dạng mong muốn. Thuật toán heuristic sử dụng một bộ quy tắc được xác định trước để xác định thông tin liên quan từ danh sách token và nhãn. Ví dụ, nếu một token có nhãn là "tên" và nhãn tiếp theo là "email", thuật toán heuristic sẽ kết hợp hai token này để tạo thành cặp tên-email. Kết quả của bước này là một định dạng có cấu trúc của thông tin được trích xuất, dễ dàng sử dụng cho các bước xử lý tiếp theo.

#### 4.2.1. Token Classification model

Phân loại token là một nhiệm vụ quan trọng trong phân tích cú pháp CV, bao gồm việc xác định và phân loại từng token trong tài liệu văn bản. Trong ngữ cảnh phân tích CV, token đề cập đến các từ hoặc cụm từ riêng lẻ tạo nên văn bản trong CV. Mục tiêu của việc phân loại token là gán mỗi token vào một trong các nhãn đã được xác định trước, chẳng hạn như trình độ học vấn, kinh nghiệm, kỹ năng hoặc thông tin liên hệ. Điều này giúp trích xuất thông tin quan trọng từ CV và tạo ra một cấu trúc có tổ chức cho nội dung của nó. Để thực hiện phân loại token trong phân tích cú pháp CV, chúng tôi đã sử dụng các mô hình học sâu để tự động phân loại từng token dựa trên ngữ cảnh và các đặc điểm của nó. BERT là một mô hình học sâu hiệu quả, đã được sử dụng rộng rãi cho các nhiệm vụ phân loại token, bao gồm cả trong phân tích cú pháp CV. BERT là một mô hình ngôn ngữ được huấn luyện trước, có thể được tinh chỉnh cho các nhiệm vụ cụ thể như phân loại token với một lượng dữ liệu nhỏ. Khi tinh chỉnh BERT, mô hình được huấn luyện để dự đoán danh mục của từng token trong tài liệu CV dựa trên ngữ cảnh xung quanh và các đặc điểm khác.
Chúng tôi cũng đã sử dụng LayoutLM để so sánh và cải thiện kết quả so với mô hình BERT. LayoutLM là một mô hình nâng cao hơn, được phát triển để cải thiện khả năng của BERT trong các tác vụ hiểu tài liệu, bao gồm phân tích cú pháp CV. Những mô hình này có thể xử lý cả đầu vào văn bản và hình ảnh, làm cho

chúng trở nên lý tưởng để phân tích các tài liệu có cấu trúc như CV. Một lợi thế đáng kể của LayoutLM so với BERT là khả năng hiểu bố cục và cấu trúc của tài liệu. Khả năng này được nâng cao nhờ việc đào tạo trước LayoutLM trên tập dữ liệu lớn về hình ảnh tài liệu, giúp mô hình hiểu các thành phần tài liệu khác nhau như hộp văn bản, bảng và hình.

Ngoài ra, LayoutLM có khả năng thực hiện dự đoán đồng thời dựa trên cả tính năng văn bản và hình ảnh, nghĩa là chúng có thể trích xuất thông tin từ nhiều nguồn khác nhau trong tài liệu. Ví dụ, LayoutLM có thể nhận dạng và trích xuất văn bản từ hình ảnh và bảng, điều này thường là thách thức đối với các mô hình dựa trên văn bản truyền thống như BERT. Đối với phân loại token, LayoutLM có thể thực hiện phân loại dựa trên cả văn bản và bố cục, cho phép phân loại chính xác từng token dựa trên cả nội dung văn bản và vị trí của nó trong tài liệu. Cách tiếp cận này đặc biệt hữu ích cho việc phân tích cú pháp CV vì nó cho phép trích xuất thông tin chính xác hơn từ các tài liệu phức tạp.

Chúng tôi đã tinh chỉnh hai mô hình tiên tiến nhất là BERT và LayoutLM trên tập huấn luyện của mình. Đối với BERT, chúng tôi đã sử dụng mô hình BERT-base-uncased được huấn luyện trước và tinh chỉnh trên tập dữ liệu của chúng tôi. Đối với LayoutLMv3, chúng tôi đã sử dụng mô hình LayoutLM tiền huấn luyện và tinh chỉnh trên tập dữ liệu của chúng tôi. Trong quá trình tinh chỉnh, chúng tôi đã sử dụng trình tối ưu hóa Adam với tốc độ học tập 2e-5, kích thước batch là 16 và độ dài chuỗi tối đa 512 token cho cả hai mô hình. Chúng tôi đã huấn luyện từng mô hình trong 10 epoch và đánh giá hiệu năng trên tập xác nhận sau mỗi epoch.

### 4.2.2. Chuyển đổi token và nhãn bằng thuật toán heuristic

Chúng tôi áp dụng thuật toán heuristic để chuyển đổi danh sách token và nhãn của chúng sang định dạng mong muốn. Sau khi áp dụng mô hình phân loại token, chúng tôi thu được danh sách token cùng với các nhãn dự đoán tương ứng. Tuy nhiên, để danh sách này trở nên hữu ích, chúng tôi cần chuyển đổi nó thành định dạng có cấu trúc như JSON, dễ dàng xử lý và sử dụng bởi các ứng dụng khác. Thuật toán heuristic của chúng tôi xem xét thứ tự và cấu trúc của các token để tạo ra định dạng đầu ra mong muốn. Đầu vào của thuật toán là một danh sách các từ điển, mỗi từ điển chứa thông tin về một hộp văn bản, bao gồm văn bản trong hộp, tọa độ của hộp và danh sách các từ trong hộp cùng với nhãn dự đoán tương ứng của chúng.

```
1. [
2.    {
3.        "chữ": "IUH UNIVERSITY",
4.        "bbox": [702, 60, 865, 102],
5.        "từ": [
6.            {
7.                "bbox": [702.0, 60.0, 778.0, 102.0],
8.                "chữ": "FPT",
9.                "sự_dự_đoán": "EDUCATION_TITLE"
10.            },
11.            {
12.                "bbox": [788.0, 60.0, 865.0, 102.0],
13.                "chữ": "UNIVERSITY",
14.                "sự_dự_đoán": "EDUCATION_TITLE"
15.            }
16.        ]
17.    }
18. ]
```

Hình 6. Dữ liệu đầu vào heuristic

Quá trình chuyển đổi bao gồm ba bước chính. Bước đầu tiên, ghép và sắp xếp các hộp giới hạn từ, bao gồm việc nối tất cả các trang, tính toán lại khung giới hạn từ bằng cách cộng độ dài của trang trước vào tọa độ dọc, và sắp xếp tất cả các hộp giới hạn theo thứ tự tăng dần dựa trên tọa độ dọc và ngang. Bước thứ hai, nhóm các từ theo nhãn dự đoán, thêm các nhóm này vào mục từ điển nhãn tương ứng. Bước thứ ba, trích

xuất thông tin trường, tìm tất cả các nhóm từ vị trí, bắt đầu, kết thúc và nội dung nằm dưới và trên nhóm phụ đề trong một khoảng cách ngưỡng nhất định, hợp nhất các nhóm này lại với nhau để tạo thành khối văn bản có cấu trúc.


```
{
    "hồ_sơ": {
        "họ_và_tên": "Lê Thị C",
        "dob": "05/09/2000",
        "giới_tính": "Nữ",
        "tiêu_đề": "Sinh viên Công nghệ Thông tin",
        "luận_văn": "https://www.linkedin.com/in/lethic",
        "địa_chỉ": "Quận Bình Thạnh, Hồ Chí Minh",
        "email": "lethic@example.com",
        "điện_thoại": "0912345678"
    },
    "khách_quan": {
        "mô_tả": "Hiện đang là sinh viên chuyên ngành Công nghệ Thông tin. Tôi đam mê nghiên cứu về Trí tuệ Nhân tạo và Phân tích Dữ liệu."
    },
    "giáo_dục": [
        {
            "trường_học": "Đại học Bách Khoa TP.HCM",
            "bắt_đầu": "09/2018",
            "kết_thúc": "06/2022",
            "chi_tiết": "Điểm trung bình: 8,2/10.",
            "tiêu_đề": "Công nghệ Thông tin - Khoa Khoa học và Kỹ thuật Máy tính"
        }
    ],
    "kinh_nghiệm": [
        {
            "công_ty": "Công ty XYZ",
            "chức_vụ": "Thực tập sinh Lập trình",
            "bắt_đầu": "06/2021",
            "kết_thúc": "09/2021",
            "kinh_nghiệm": "Phát triển và bảo trì các ứng dụng web, tham gia vào các dự án phát triển phần mềm."
        }
    ],
    "nhóm_kỹ_năng": [
        {
            "khu_vực": "Ngôn ngữ",
            "mô_tả_kỹ_năng": "Tiếng Anh, Tiếng Nhật"
        },
        {
            "khu_vực": "Lập trình",
            "mô_tả_kỹ_năng": "Java, Python, JavaScript, HTML/CSS, SQL"
        },
        {
            "khu_vực": "Công cụ",
            "mô_tả_kỹ_năng": "Git, Docker, Kubernetes, Jenkins"
        }
    ]
}
```


Hình 7. Kết quả đầu ra giải thuật heuristic

## 5. THỰC NGHIỆM ĐÁNH GIÁ VÀ KẾT LUẬN

### 5.1. KẾT QUẢ THỰC NGHIỆM

Để đánh giá hiệu quả mô hình phân loại token chúng tôi đã thực hiện bằng cách sử dụng nhiều số liệu khác nhau để đảm bảo độ chính xác và hiệu suất cao cụ thể là 3 thang đó phổ biến là F1-Score, Precision và

Recall. F1-Score là số liệu được sử dụng phổ biến nhất, vì nó cung cấp một điểm trung bình hài hòa giữa Precision và Recall, giúp đánh giá cân bằng hiệu suất tổng thể của mô hình. Precision đo lường tỷ lệ các dự đoán chính xác trong số tất cả các dự đoán tích cực, trong khi Recall đo lường tỷ lệ các dự đoán chính xác trong số tất cả các trường hợp thực tế.

Chúng tôi cũng áp dụng các số liệu đánh giá ở các cấp độ khác nhau, bao gồm cấp token và cấp tài liệu. Số liệu cấp token đánh giá hiệu suất của mô hình ở mức từ hoặc từ phụ riêng lẻ, trong khi số liệu cấp tài liệu đánh giá hiệu suất tổng thể trên toàn bộ tài liệu hoặc tập hợp tài liệu, bao gồm cả F1-Score trung bình trên tất cả các hồ sơ ứng viên trong tập dữ liệu.

Phương pháp đánh giá toàn diện này đảm bảo rằng mô hình được kiểm tra kỹ lưỡng ở nhiều khía cạnh khác nhau, cung cấp thước đo chính xác và đáng tin cậy về hiệu quả của mô hình trong việc phân tích các hồ sơ của ứng viên.

| **Mô hình** | **Precision** | **Recall** | **F1-Score** |
|---|---|---|---|
| BERT | 0,713 | 0,721 | 0,722 |
| LayoutLM | 0,824 | 0,835 | 0,843 |

Bảng 3. Kết quả của mô hình BERT và LayoutLM trên tập dữ liệu thử nghiệm

Nghiên cứu đã so sánh hiệu năng của hai mô hình trên tập dữ liệu thử nghiệm của chúng tôi và báo cáo kết quả để thể hiện chi tiết quả (Bảng 3).

## 5.2. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

### 5.2.1. Kết luận

Trong nghiên cứu này, chúng tôi đã trình bày một phương pháp tiếp cận để phân tích sơ yếu lý lịch tự động bằng cách sử dụng mô hình phân loại văn bản dựa trên deep learning. Mô hình đề xuất của chúng tôi đã được đào tạo trên một tập dữ liệu lớn gồm các định dạng sơ yếu lý lịch đa dạng và đạt được độ chính xác cao trong việc xác định các phần và thực thể chính của sơ yếu lý lịch. Kết quả cho thấy mô hình BERT đạt được Precision là 0,713, Recall là 0,721 và F1-Score là 0,722. Trong khi đó, mô hình LayoutLM vượt trội hơn với Precision là 0,824, Recall là 0,835 và F1-Score là 0,843.

Hiệu suất của LayoutLM cao hơn BERT đáng kể, điều này có thể được giải thích bởi khả năng của LayoutLM trong việc xử lý cả văn bản và hình ảnh, giúp mô hình này hiểu rõ hơn về bố cục và cấu trúc của tài liệu. Khả năng này giúp LayoutLM phân loại các token chính xác hơn, đặc biệt là trong các tài liệu có cấu trúc phức tạp như sơ yếu lý lịch. Precision cao của LayoutLM cho thấy mô hình này ít dự đoán sai các nhãn, trong khi Recall cao chỉ ra rằng mô hình này có khả năng nhận diện đầy đủ các thực thể quan trọng trong văn bản.

Cách tiếp cận của chúng tôi có một số ưu điểm so với các phương pháp truyền thống, bao gồm độ chính xác cao hơn, thời gian xử lý nhanh hơn và khả năng xử lý nhiều định dạng sơ yếu lý lịch khác nhau. Tuy nhiên, phương pháp của chúng tôi cũng có một số hạn chế. Đầu tiên, việc phụ thuộc vào dữ liệu huấn luyện chất lượng cao là một thách thức, vì các mẫu sơ yếu lý lịch không đồng nhất và có thể thay đổi đáng kể về định dạng và nội dung. Thứ hai, mặc dù LayoutLM có khả năng xử lý cả văn bản và hình ảnh, nhưng việc xử lý các tài liệu có cấu trúc phức tạp vẫn còn gặp khó khăn, đặc biệt là khi các yếu tố đồ họa và bố cục không tuân theo các quy tắc chuẩn. Cuối cùng, thời gian và tài nguyên cần thiết để huấn luyện và tinh chỉnh các mô hình deep learning lớn như BERT và LayoutLM là rất lớn. Chúng tôi tin rằng phương pháp tiếp cận của mình có tiềm năng đáng kể để sử dụng trong môi trường doanh nghiệp, nơi việc phân tích sơ yếu lý lịch hiệu quả và chính xác là rất quan trọng để tuyển dụng thành công.

### 5.2.2. Hướng phát triển

Trong tương lai, chúng tôi sẽ tập trung vào việc tăng cường dữ liệu huấn luyện để cải thiện hơn nữa độ chính xác của mô hình. Việc mở rộng tập dữ liệu với nhiều định dạng và ngôn ngữ khác nhau, đặc biệt là tiếng Việt, sẽ giúp mô hình trở nên linh hoạt và ứng dụng rộng rãi hơn. Đảm bảo rằng nó có thể hoạt động hiệu quả trong các bối cảnh ngôn ngữ đa dạng. Hơn nữa, chúng tôi sẽ tiếp tục tối ưu hóa mô hình để giảm thời gian xử lý và nâng cao hiệu suất tổng thể, nhằm đáp ứng nhu cầu của các doanh nghiệp trong việc phân tích và tuyển dụng nhân sự từ sơ yếu lý lịch.

## TÀI LIỆU THAM KHẢO

[1] Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2018). Bert: Pre-training of deep bidirectional transformers for language understanding. arXiv preprint arXiv:1810.04805.

[2] Xu, Y., Li, M., Cui, L., Huang, S., Wei, F., & Zhou, M. (2020, August). Layoutlm: Pre-training of text and layout for document image understanding. In Proceedings of the 26th ACM SIGKDD international conference on knowledge discovery & data mining (pp. 1192-1200).

[3] Xu, Y., Xu, Y., Lv, T., Cui, L., Wei, F., Wang, G., ... & Zhou, L. (2020). Layoutlmv2: Multi-modal pre-training for visually-rich document understanding. arXiv preprint arXiv:2012.14740.

[4] Hong, T., Lee, J., & Kang, S. (2021). BROS: A Transformer-based Baseline for Form Understanding.

[5] Das, D., Sanyal, A., & Chatterjee, M. (2020). Named Entity Recognition for Resume Parsing: A Big Data Approach.

[6] Sanyal, A., Chatterjee, M., & Das, D. (2020). Automated Resume Parsing using NLP Techniques.

[7] Berty, P., Gunawan, Y., & Devis, Y. (2021). Deep Learning Approach for Resume Parsing in Indonesian Language.

[8] Wikipedia tiếng Việt. (2021). Trích xuất thông tin. Truy cập từ: https://vi.wikipedia.org/wiki/Tr%C3%ADch_xu%E1%BA%A5t_th%C3%B4ng_tin.

[9] VCgate. (2021). Tư liệu khoa học Việt Nam. Truy cập từ: https://vcgate.vnu.edu.vn/.

[10] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. Advances in neural information processing systems, 30.